Reconnaissance et analyse automatique d'expressions faciales







Du CNN sur FER2013 à la détection multi-visages avec YOLO

Attia Hanine & Laabidi Raef

Objectif : de l'image brute à l'expression prédite

Classification multiclasse : 7 expressions, 7 neurones de sortie, activation Softmax.

Image / Vidéo
entrée

YOLO-Face
où sont les visages ?

Extraction
gris · 48×48 · /255

CNN
3 blocs conv + pooling

Softmax
7 probabilités

Résultat
boîte + expression + score

Parties 1–6 : quelle expression ?

Parties 8–9 : où sont les visages ?

Socle

Données, baseline dense, CNN, entraînement, évaluation, 5 expériences

Extension

Détection multi-visages avec YOLO-Face sur image (partie 8)

Bonus

Traitement d'une vidéo image par image (partie 9)

Dataset : FER2013

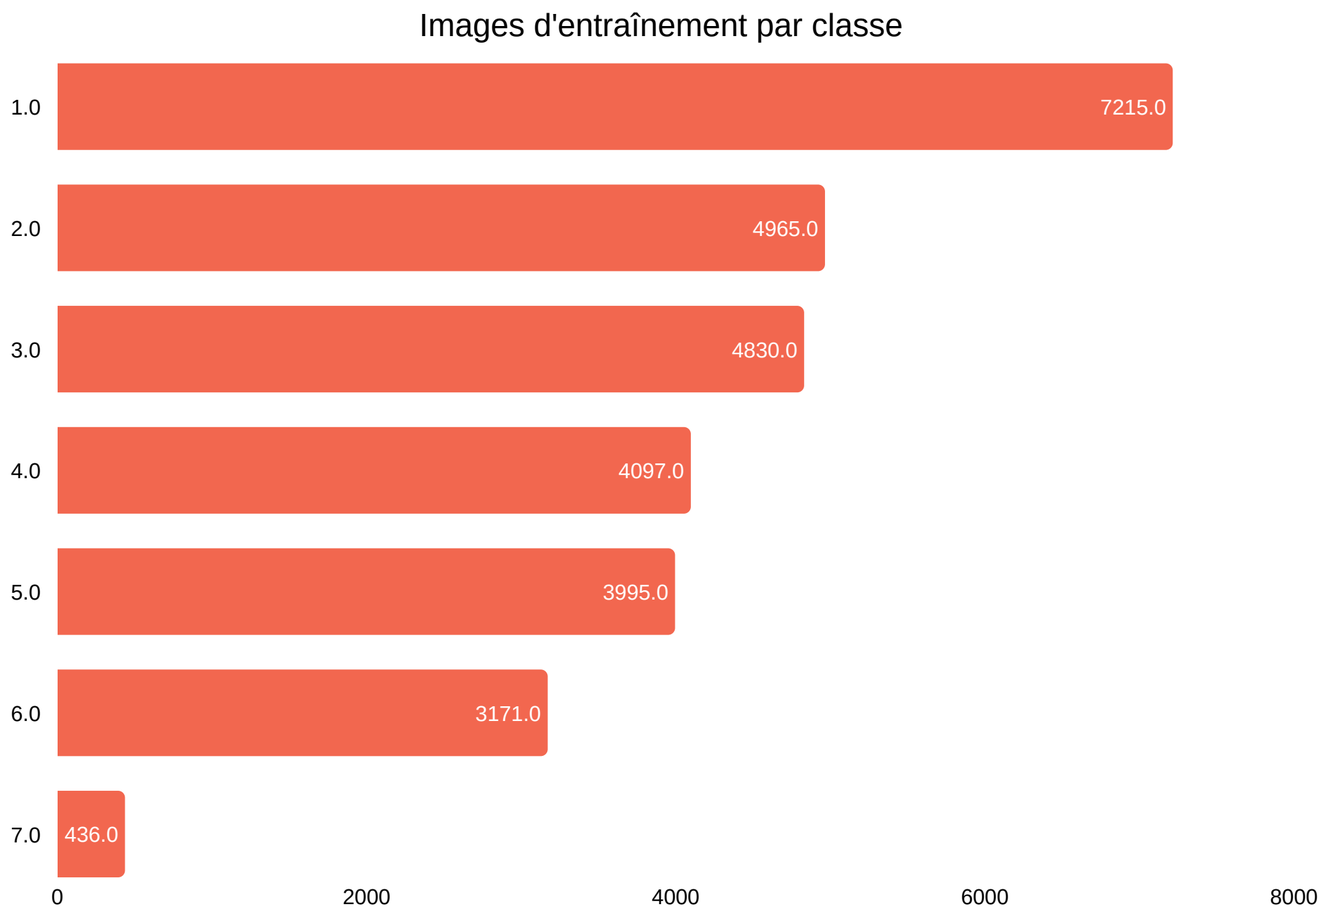
35 887
images au total

7
classes

48×48
pixels, 1 canal gris

28 709
train (+ 7 178 test)

Source : Kaggle (Goodfellow et al., 2013)
Licence : CC0 1.0 (domaine public)
Déséquilibre : « disgust » ≈ 16× moins d'images que « happy »



Préparation des données

1. **Validation 20 %**
   split stratifié du train : 22 967 train · 5 742 val

2. **Normalisation**
   pixels 0–255 → 0–1 (division par 255)

3. **Canal**
   (48, 48) → (48, 48, 1) pour Conv2D

4. **Labels**
   entiers 0 à 6, perte sparse_categorical

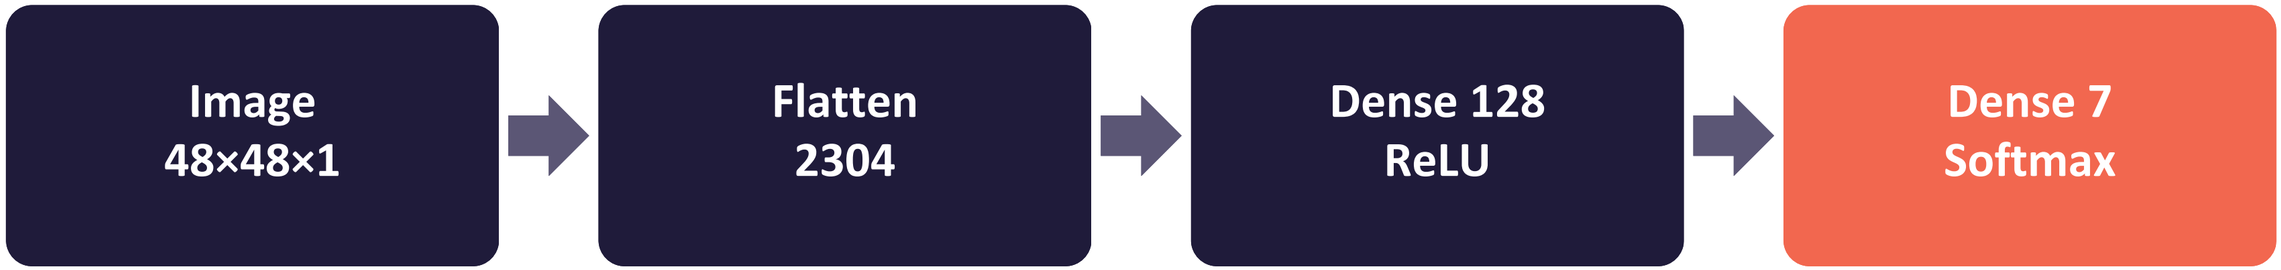
5. **Test réservé**
   7 178 images, évaluation finale uniquement



Un exemple par classe (FER2013, 48×48, niveaux de gris)

Le test ne sert jamais de validation pendant l'entraînement.

Modèle de référence : réseau dense



295 943
paramètres entraînables

37,3 %
accuracy sur le test

Adam
perte : sparse categorical CE

Limite : Flatten dès l'entrée fait perdre la position des pixels. Un CNN exploite la structure spatiale de l'image avec peu de paramètres par filtre.

Architecture du CNN de référence

Couche	Sortie	Paramètres
Entrée (gris)	48 × 48 × 1	0
Conv2D 32 · 3×3 · same · ReLU	48 × 48 × 32	320
MaxPooling 2×2	24 × 24 × 32	0
Conv2D 64 · 3×3 · same · ReLU	24 × 24 × 64	18 496
MaxPooling 2×2	12 × 12 × 64	0
Flatten	9 216	0
Dense 128 · ReLU	128	**1 179 776**
Dense 7 · Softmax	7	903

1 199 495

paramètres au total

Pourquoi ce choix ?

- Images petites : réseau peu profond suffisant
- 32 → 64 filtres : motifs simples puis complexes
- Kernel 3×3 : bon compromis local / paramètres

Entraînement : choix et justification

Perte

sparse_categorical_crossentropy

multiclasse, labels entiers

Optimiseur

Adam (learning rate par défaut)

mise à jour adaptative des poids

Batch size

64

compromis stabilité / mémoire

Époques

20 (au maximum)

les courbes décident de l'arrêt

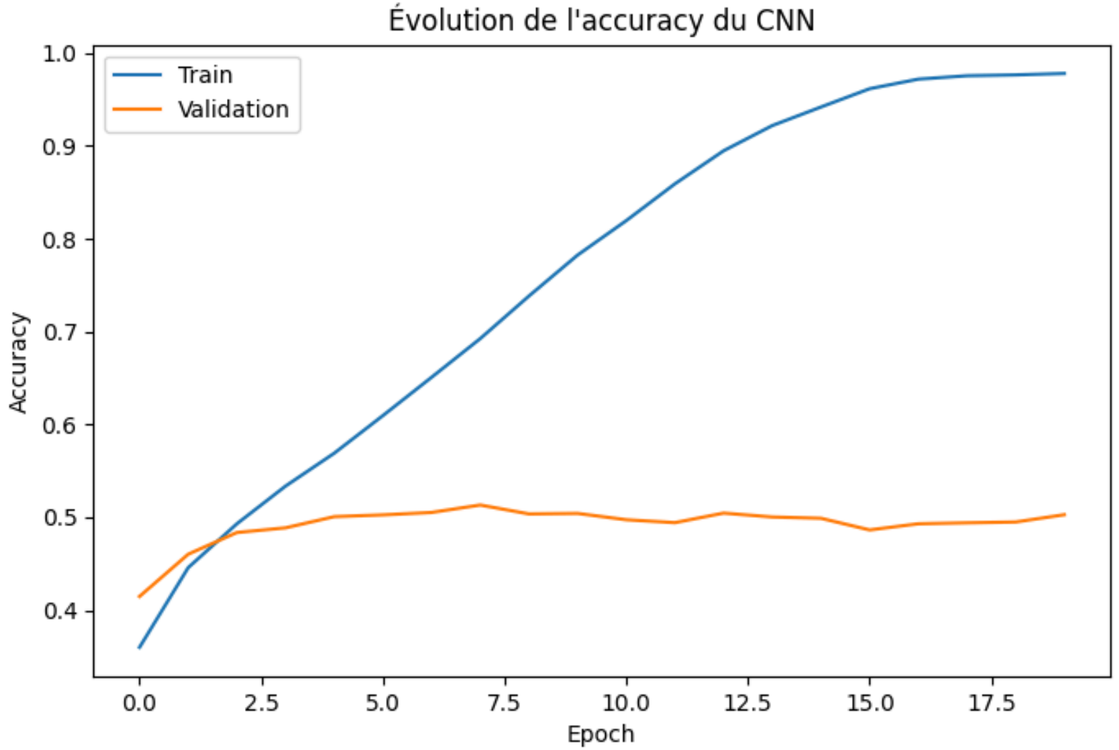
Métriques

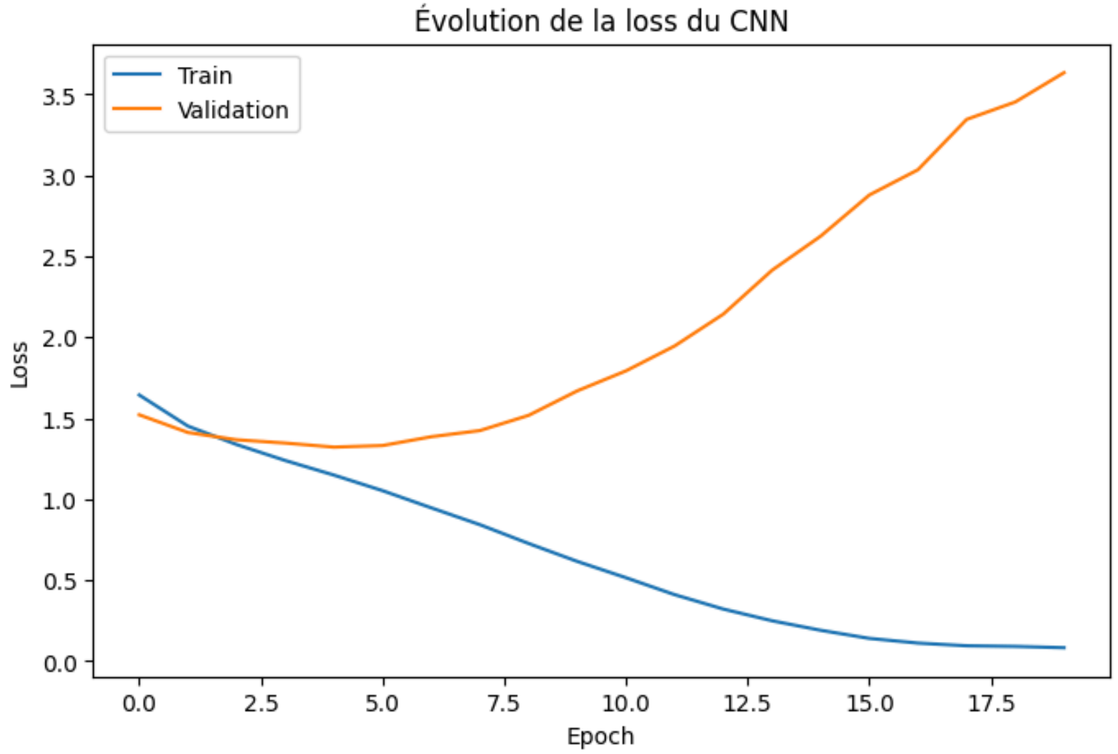
loss et accuracy

suivies sur train et validation

22 967 images d'entraînement · 5 742 de validation · 359 mises à jour par époque

Résultat : un fort surapprentissage





98 % → 51 %

train → validation

1,32 → 3,63

val. loss, époque 5 → 20

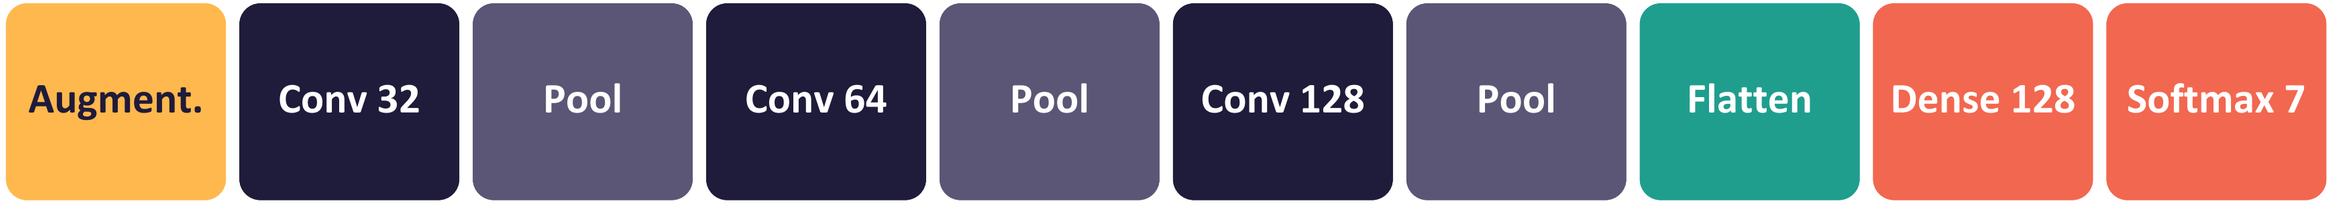
Test : 50,3 % pour le CNN contre 37,3 % pour le réseau dense.

Expériences : une modification à la fois

Modèle	Modification	Val. acc.	Observation
Référence	2 blocs conv (32 → 64)	51,31 %	Fort surapprentissage
Exp. 1	Dropout 0,5	52,68 %	Réduit le surapprentissage
Exp. 2	Data augmentation	53,29 %	Faible écart train / val.
Exp. 3	Early stopping	52,28 %	Arrêt à 9 époques sur 20
Exp. 4	3e bloc conv (128 filtres)	56,22 %	Meilleur score, mais ≈ 97 % en train
Exp. 5	BatchNorm + Dropout + GAP + aug.	54,81 %	Plus complexe, plus lent, sans gain
Final	**3 conv + augmentation + early stopping**	**55,80 %**	**Meilleur compromis**

Chaque expérience modifie un seul paramètre pour pouvoir interpréter son effet.

Modèle final : profondeur + régularisation



Early stopping : surveille val_loss, patience 3, restaure les meilleurs poids

683 527
paramètres

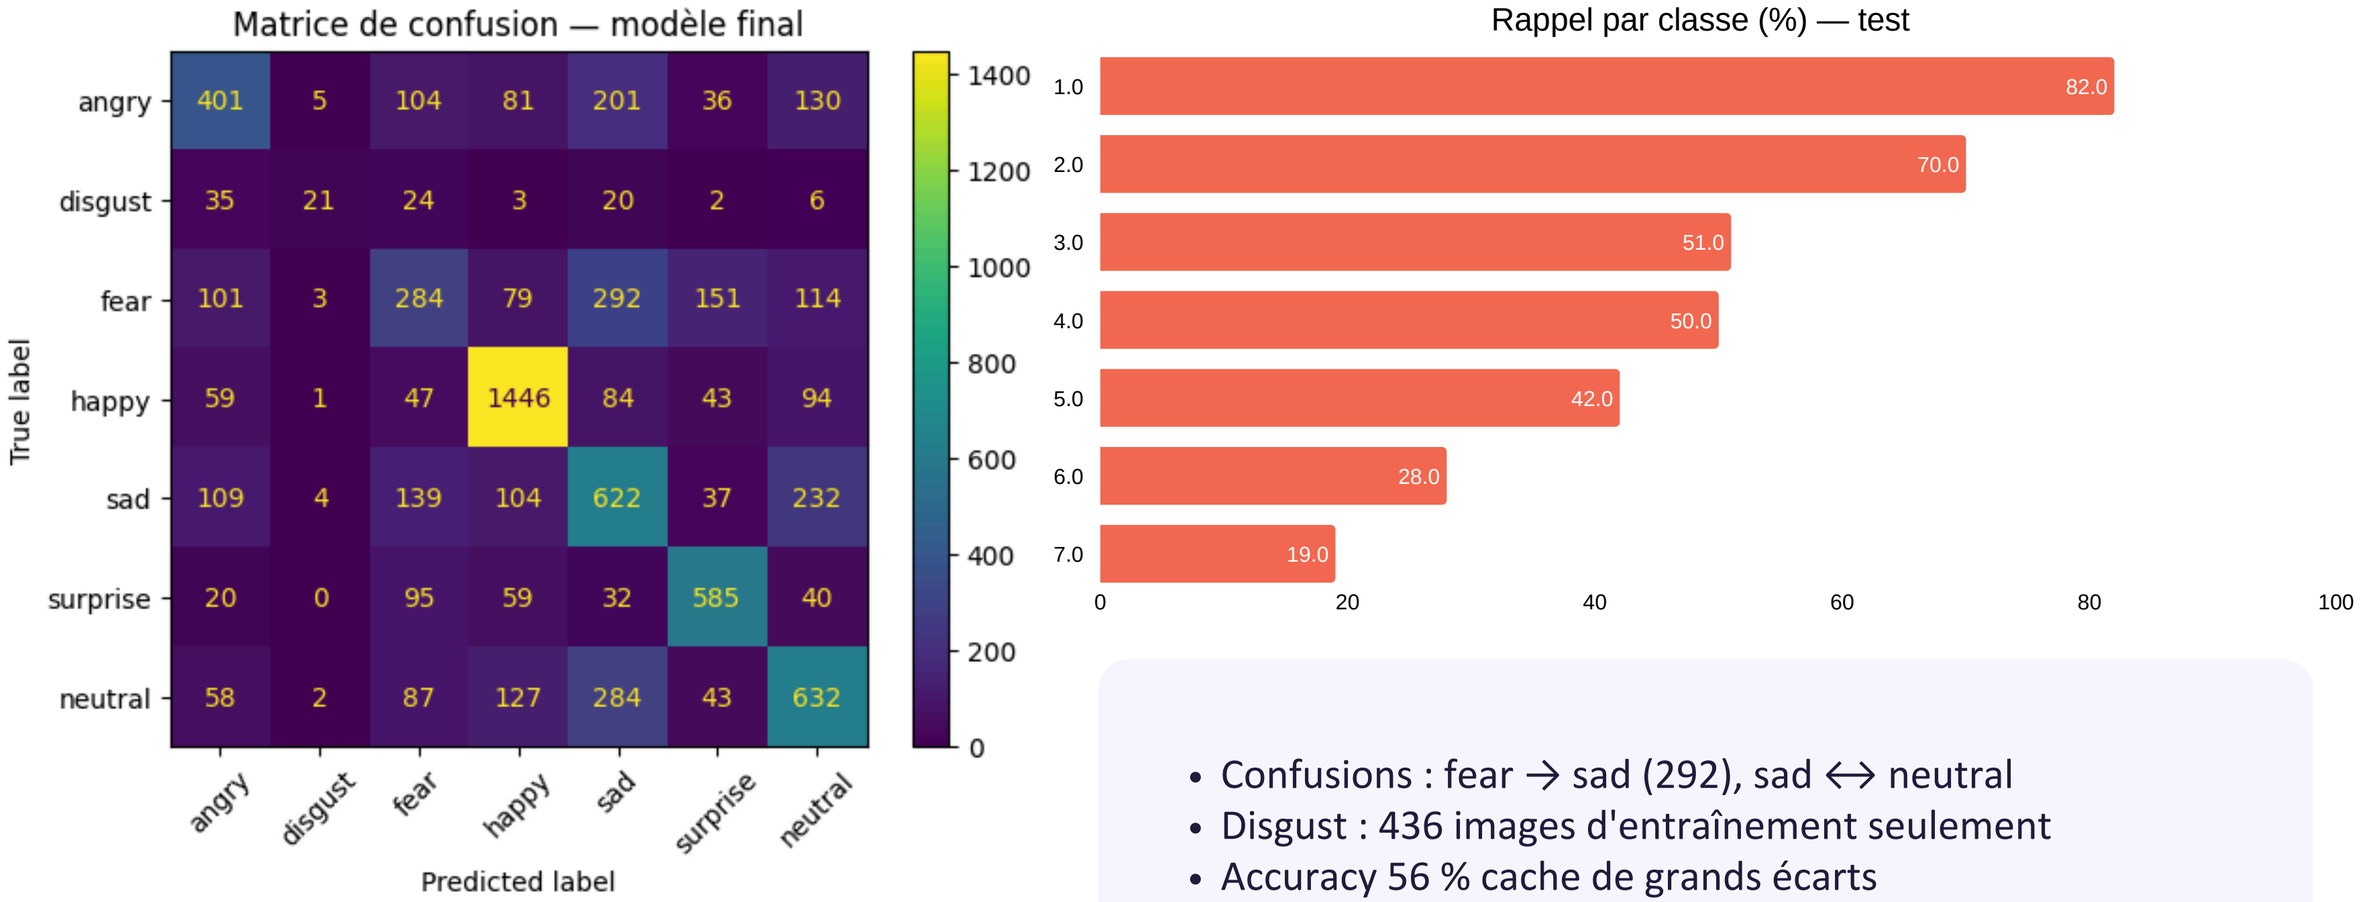
55,8 %
meilleure val. accuracy

≈ 0,6 pt
écart train / val.

55,6 %
accuracy sur le test

Référence → final sur le test : accuracy 50,3 % → 55,6 %, loss 3,54 → 1,17.
Pourquoi pas l'expérience 4 seule ? 56,2 % en validation mais ≈ 97 % en entraînement : elle mémorise.

Analyse des erreurs par classe



Matrice de confusion — modèle final (test)

- Confusions : fear → sad (292), sad ↔ neutral
- Disgust : 436 images d'entraînement seulement
- Accuracy 56 % cache de grands écarts

Extension : détecter plusieurs visages avec YOLO

1. **Détection**
   YOLOv8n-face, seuil 0,25

2. **Extraction**
   recadrage de chaque boîte

3. **Prétraitement**
   gris · 48×48 · ÷255, comme à l'entraînement

4. **Prédiction**
   CNN final + Softmax

5. **Affichage**
   boîte · expression · score



12
visages détectés

Visages bien détectés ; expressions parfois erronées (limite du classifieur).

Bonus : extension à la vidéo



197
images traitées

1 / visage
prédiction par image

H.264
export compatible (ffmpeg)

Limite : pas de suivi d'identité entre les images, donc le label d'une même personne peut changer d'une frame à l'autre.

Ce que nous retenons

Résultats

- Réseau dense : 37,3 %
- CNN de référence : 50,3 %
- Modèle final : 55,6 % (test)

Leçons

- Le CNN exploite la structure spatiale
- Augmentation + early stopping : meilleure généralisation
- Le meilleur score isolé n'est pas le meilleur modèle

Limites et suites

- Fear et disgust restent difficiles
- Pondération des classes, transfer learning
- Suivi des visages dans la vidéo

Merci · Questions ?